

AWS DataSync로 클라우드 간 데이터 옮기기

Presenter: Daehyun Kim
Solutions Architect, MegazoneSoft
前 kakaostyle

자기소개

김대현

- Solutions Architect @MegazoneSoft
 - Google Cloud (AI/ML)
- 前 Data Quality Assurance kakaostyle

- 춘식을 좋아하는 사람 좋아 인간입니다
- 현재 AWSKRUG 대학생 소모임 (AUSG)에서 주로 활동하고 있습니다
- 어떻게하면 고객에게 좋은 Solution을 제시할 수 있을지 고민중입니다
- 본업은 Google Cloud 쪽이지만... AWS가 더 친숙합니다 (자격증도 있어요)



Daehyun Kim



Daehyun-Bigbread



developer._.toby

오늘 이야기 해볼것

- what is AWS Datasync?
- 이걸 왜 쓰게 되었는지
- Datasync를 굳이 사용했어야 했나? 고민
- 어떻게 구축 & 설정했는지?
- 트러블슈팅 & 느낀점

What is AWS Datasync?

Link: https://docs.aws.amazon.com/ko_kr/datasync/latest/userguide/what-is-datasync.html



AWS Datasync

AWS DataSync는 스토리지 서비스 간에 AWS 파일 또는 객체 데이터를 빠르고 쉽게 전송할 수 있는 안전하고 안정적인 고속 파일 전송 서비스입니다.


- 온프레미스(NFS, HDFS - Hadoop 분산 파일 시스템), 객체 스토리지
- AWS Storage (S3, EFS, FSx..)
- 다른 Cloud Storage (Google Cloud Storage, Azure Files, OCI Object Storage)

사용사례: 데이터 마이그레이션 , 데이터 복제, Cloud 내 처리를 위한 데이터 전송

What is AWS Datasync?

Datasync 전송 아키텍처 - AWS 스토리지 서비스와 다른 클라우드의 스토리지 시스템 간 전송

- DataSync를 사용하면 다른 클라우드 스토리지 시스템과 AWS 서비스사이에 데이터를 전송할 수 있습니다.
- Amazon S3, Amazon EFS, Amazon FSx for Windows File Server, Amazon FSx for Lustre, Amazon FSx for OpenZFS, Amazon FSx for NetApp ONTAP
- 중요한 개념은 3가지. Location (어디서/어디로), Task (어떻게), Execution (실행)



Amazon S3



Amazon EFS



Amazon FSx

이걸(Datasync) 왜 쓰게 되었는지?



이걸(Datasync) 왜 쓰게 되었는지?

회사일은 아니고.. 사이드 프로젝트로 학교 졸업프로젝트를 하고 있었어요.

주제는 RAG 기반 청년관련 정책을 소개 및 답변을 제공하는 Product를 만드는것.


원래는 학교에서 제공해주는 AWS 계정을 활용하여 Product의 인프라를 구축하려고 했으나?
이게 개인 졸업 논문이랑도 엮여 있는 프로젝트라.. 급한대로 Google Cloud에 있는 크레딧을
활용하여 RAG Pipeline 부분만 구축 시작...!

Google Developer Program premium benefit - CREDIT_TYPE_ANNUAL	✓ 사용 가능	96%	₩687,076.96	₩715,040.00	일회성
Google Developer Program premium benefit - CREDIT_TYPE_GEMINI	✓ 사용 가능	98%	₩70,308.24	₩71,504.00	일회성

나는야 크레딧 부자 (GCP만...)

이걸(Datasync) 왜 쓰게 되었는지?


초기에 구축한 Google Cloud 기반 아키텍처



간단한 아키텍처 설명

- Airflow(DAG)로 데이터 수집 (크롤링, API)
- 크롤링한 데이터를 VectorDB에 저장 (GCS, Metadata - MongoDB)
- RAG pipeline에 활용하기 위해 적재된 index 데이터를 로드
- LiteLLM을 활용하여 여러 LLM Model Inference Test (GPT, Claude, Gemini, Llama)
- RAG의 답변 품질을 평가

이걸(Datasync) 왜 쓰게 되었는지?




Airflow 기반 ETL Pipeline

앞에서 말씀드렸지만..? 팀 프로젝트에 사용할 수 있는 AWS 계정을 받고, 구축했던 인프라를 AWS로 마이그레이션 해야하는 이슈가 발생.

근데, 회사 & 학교를 병행하는 저의 입장으로선 인프라 전체를 마이그레이션 하기엔? 시간 & 비용적으로 문제, 또한 마이그레이션 작업을 혼자 해야하는 이슈가 존재.



그래서? ETL Pipeline은 살리고, RAG에 활용되는 Index 데이터를 AWS로 옮겨서 활용해보자!

이걸(Datasync) 왜 쓰게 되었는지?



Airflow 기반 ETL Pipeline

Data Crawling & DAG 기반 RAG에 활용되는 Index Build



Datasync를 굳이 사용했어야 했나?

그러면? 여러개의 선택지 중에 AWS Datasync를 사용하기로 결정한 이유?

방식	문제
cron	failover login, 검증. 실패알림을 전부 스크립트로 제작해야함
Storage Transfer	GCP 쪽 Managed Service라 → AWS IAM, 배포 트리거와 붙지 않음. (제어권 문제 존재)
boto3	HMAC 정적키를 서빙 서버까지 전파 = 보안적으로 문제가 있을수 있음
DataSync	관리형으로 충족. Location 기반 인증분리가 가능함으로 안정적으로 관리 가능


기존 대안들(cron, Storage Transfer, boto3)은 각각 유지보수 부채, 제어권 방향, 보안 위험이라는 치명적인 단점이 하나씩 존재. 이를 모두 극복하고, 인증을 안전하게 격리하면서도 편리하게 사용할 수 있는 관리형 서비스인 AWS DataSync를 솔루션으로 채택

어떻게 구축 & 설정했는지?




설명드리기 전에, 어떻게 아키텍처를 재설계 했을까?

GCP에 올라가 있는 Data pipeline만 살리고, Litellm기반 inference & Serving Layer 부분을 AWS쪽에 구축하여 설계



어떻게 구축 & 설정했는지?



- Route 53과 CloudFront를 거쳐 사용자 트래픽 라우팅
- RAG 백엔드 파이프라인 구성: 백엔드 EC2에서 FastAPI, LangChain, Docker를 기반으로 RAG 구축
- S3(Index Bucket)에서 로드한 데이터를 활용하여 Faiss(In-memory) 기반으로 벡터 Retrieve 수행
- LiteLLM을 활용하여 다양한 LLM 모델(GPT, Claude, Gemini, Llama) 추론 테스트 및 외부 모델 API(OpenAI, HuggingFace) 연동
- GitHub Actions와 ECR을 거쳐 SSH 및 Docker Compose를 통한 CI/CD 적용
- 별도의 모니터링 인스턴스를 구축, 시스템 상태 및 파이프라인 모니터링 수행

어떻게 구축 & 설정했는지?

이제 Datasync를 사용하기로 결정했고? 공식문서를 찾아보면서 하나하나 해봤습니다

aws

시작하기 서비스 가이드 개발자 도구 AI 리소스

🔍 본 가이드 검색

콘솔에 로그인

AWS DataSync
사용 설명서

<

AWS DataSync란 무엇인가요?
작동 방식

▶ 시작하기

▶ 네트워크 연결

▼ 데이터 전송

데이터를 어디로 전송할 수 있나요?

▶ 온프레미스 스토리지와 전송

▶ AWS 스토리지로 또는 스토리지에서 전송

▼ 다른 클라우드 스토리지로 간 전송

타사 클라우드 스토리지 시스템과 전송 계획

Google Cloud Storage로 전송 구성

Microsoft Azure Blob Storage를 사용하여 전송 구성

Microsoft Azure Files를 사용하여 전송 구성

다른 클라우드 객체 스토리지를 사용한 전송 구성

▶ 데이터 전송을 위한 작업 생성

데이터 전송 작업 시작

▶ 데이터 전송 모니터링

설명서 > AWS DataSync > 사용 설명서

Google Cloud Storage를 사용하여 AWS DataSync 전송 구성

↓ PDF

↓ RSS

↓ Markdown

☐ 포커스 모드

ⓘ 기계 번역으로 제공되는 번역입니다. 제공된 번역과 원본 영어의 내용이 상충하는 경우에는 영어 버전이 우선합니다.

를 사용하면 Google Cloud Storage와 다음 AWS 스토리지 서비스 간에 데이터를 전송할 AWS DataSync수 있습니다.

- Amazon S3
- Amazon EFS
- Amazon FSx for Windows File Server
- Amazon FSx for Lustre
- Amazon FSx for OpenZFS
- Amazon FSx for NetApp ONTAP

전송 설정을 시작하려면 Google Cloud Storage의 위치를 생성합니다. 이 위치를 전송의 소스 또는 대상으로 사용할 수 있습니다. DataSync 에이전트는 Google Cloud Storage와 Amazon EFS 간에, 또는 Amazon FSx 간에 데이터를 전송하는 경우나 기본 모드 작업을 사용하는 경우에만 필요합니다. Google Cloud Storage와 Amazon S3 간 확장 모드 데이터 전송에는 에이전트가 필요하지 않습

이 페이지에서

개요

비용

사전 조건

Google Cloud Storage 버킷에 HMAC 키 생성

2단계: 사용자 네트워크 구성

3단계: DataSync 에이전트 생성 (선택 사항)

4단계: Google Cloud Storag 버킷에 DataSync 소스 위치 생성

5단계: S3 버킷용 DataSync 대상 위치 생성

6단계: DataSync 작업 생성 및 시작

페이지 내용이 도움이 되었습니까?

전송에 기본 모드를 사용하는 경우 Google Cloud Storage 또는 Amazon VPC에 에이전트를 배포할 수 있습니다.

Agent in Google Cloud

Agent in your VPC


1. Google Cloud 환경에 DataSync 에이전트를 배포합니다.
2. 에이전트는 해시 기반 메시지 인증 코드(HMAC) 키를 사용하여 Google Cloud Storage 버킷을 읽습니다.
3. Google Cloud Storage 버킷의 객체는 퍼블릭 엔드포인트를 사용하여 TLS 1.3 AWS 클라우드로 안전하게 전송됩니다.
4. DataSync 서비스는 S3 버킷에 데이터를 씁니다.

다음 다이어그램에서 전송을 보여 줍니다.

The diagram illustrates the data transfer process. On the left, under 'Other cloud provider', a 'Bucket with objects' (represented by a green bucket icon) is connected via a dashed double-headed arrow to a 'DataSync agent' (represented by a blue square icon with a double arrow). A solid arrow labeled 'TLS 1.3' points from the 'DataSync agent' to the 'DataSync service' (represented by a green square icon with a cloud and double arrow) within the 'AWS Cloud' environment. The 'AWS Cloud' environment is shown as a large box containing an 'AWS Region' box. Inside the 'AWS Region' box, the 'DataSync service' is connected via a solid arrow to an 'Amazon S3 bucket' (represented by a yellow bucket icon).

어떻게 구축 & 설정했는지?

물론 처음해보는거라... 어려웠습니다... 그래도 제가 어떻게 했는지 설명을 한번 드려보면?



어떻게 구축 & 설정했는지?

마이그레이션 및 전송

AWS DataSync

데이터 이동 간소화, 자동화 및 가속화

AWS DataSync는 온라인 데이터 이동 및 검색 서비스입니다. 이 서비스를 이용하면 AWS로의 데이터 마이그레이션이 간소화되고 속도가 빨라지며, 온프레미스 스토리지, 엣지 로케이션, 다른 클라우드 제공업체 및 AWS 스토리지 서비스 사이를 오가며 데이터를 이동하기 간편해집니다.

데이터 전송 태스크 생성

설정할 데이터 전송을 선택합니다.

- ☒ 온프레미스 스토리지와 AWS 간
- ☐ 다른 클라우드와 AWS 간
- ☐ AWS 스토리지 서비스 간

시작하기

요금

선불 비용이나 최소 비용이 없습니다. 스토리지 위치 간에 전송된 데이터 양만큼 기가바이트당 정액 요금을 지불합니다. 향상됨(Enhanced) 모드로 구성된 태스크도 태스크 실행 건당 요금이 부과됩니다. 이러한 요금은 데이터를 이동, 확인, 동기화하는 데 쓰이는 서비스 관리형 클라우드 인프라 사용에 적용됩니다. 또한 데이터 저장소에서 읽고 저장소에 쓰는 작업에는 표준 요청 및 데이터 전송 요율로 요금을 부과합니다.

[DataSync 요금에 대해 자세히 알아보기](#)

추가 정보

[설명서](#)

[API 참조](#)

작동 방식

1. 온프레미스 스토리지 또는 다른 클라우드 스토리지와 AWS 간에 데이터를 전송하려면 에이전트 배포

DataSync 에이전트를 배포하고 AWS 계정에 연결합니다. 동일한 AWS 계정 내에서 AWS 스토리지 서비스 간에 데이터를 전송할 때는 에이전트를 배포할 필요가 없습니다.

2. 태스크 생성

데이터 원본 및 대상의 위치를 지정하고 전송을 구성하는 데 사용할 옵션을 지정하여 태스크를 생성합니다.

3. 전송 시작

콘솔 또는 Amazon CloudWatch를 사용하여 태스크를 시작하고 데이터 이동을 모니터링합니다.

AWS Console에서 Datasync로 접속

- 데이터 전송 Task를 설정할 수 있음
 - 온프레임 Storage - AWS
 - 다른 클라우드 - AWS
 - AWS 스토리지 서비스간

Google Cloud Storage (GCS)에 적재된 FAISS Index를 가져와야 함.

다른 클라우드(GCP)와 AWS간 으로 설정

그 전에, 데이터를 받을 수 있는 S3를 미리 생성해야합니다!!!


어떻게 구축 & 설정했는지?

Datasync Task 구성 - 소스 위치 구성 (어디서 데이터를 가져올지 설정)

The screenshot shows the AWS DataSync console interface. The left sidebar indicates the current step is '1단계 소스 위치 구성' (Step 1: Source Location Configuration). The main content area is titled '소스 위치 구성 정보' (Source Location Configuration Information). It contains two main sections: '소스 위치 옵션' (Source Location Options) and '구성' (Configuration). In the '소스 위치 옵션' section, '소스 위치 생성 또는 선택' (Create or select source location) is set to '데이터를 전송할 소스 위치 선택' (Select source location to transfer data to), with '새 위치 생성' (Create new location) selected. The '구성' section includes: '위치 유형' (Location type) set to '객체 스토리지' (Object storage); '리전' (Region) set to 'Asia Pacific (Seoul) ap-northeast-2'; '서버' (Server) set to 'storage.googleapis.com'; '버킷 이름' (Bucket name) set to 'scd26-crosscloud-handson'; and '폴더' (Folder) set to '/sample-docs/'. There is also an unchecked checkbox for '에이전트 사용' (Use agent).

Google Cloud Storage (GCS)도 객체 Storage,

객체 유형 - 객체 스토리지로 설정
서버 - Google Cloud의 서버 URL로 설정
버킷 이름 - 그대로
폴더 - Storage 폴더 이름 그대로



어떻게 구축 & 설정했는지?

Datasync Task 구성 - 인증 부분 구성

- 데이터를 가져올 클라우드에 인증정보를 가져와서 입력

인증

☒ 자격 증명 필요 ☐ 자격 증명이 필요하지 않음

액세스 키
버킷에 액세스하는 데 필요한 액세스 키입니다.

비밀 키
☒ 키 지정 ☐ Secrets Manager 시크릿 사용
버킷에 액세스하는 데 필요한 비밀 키입니다.

☒ 시크릿 키 표시
KMS 키 ARN(선택 사항)
선택적 KMS 키 ARN을 입력하여 시크릿 키를 암호화합니다.

Datasync Task 대상 위치 생성

- 받은 데이터를 어디에 저장할지 설정

대상 위치 구성

대상 위치 옵션
대상 위치 생성 또는 선택
데이터를 전송할 대상 위치 선택
☒ 새 위치 생성 ☐ 기존 위치 선택

구성
위치 유형
Amazon S3
에이전트가 없는 객체 스토리지 상태에서의 전송은 Amazon S3로만 전송할 수 있습니다.
리전
Asia Pacific (Seoul) ap-northeast-2
S3 URI
 보기 S3 둘러보기
S3 스토리지 클래스
객체를 전송할 스토리지 클래스를 선택합니다.
Standard
IAM 역할
S3 버킷에 액세스하는 데 사용됩니다. 자세히 알아보기
AWSDatasyncS3BucketAccess-scd26-handson-rag-docs-toby-5f6... 자동 생성됨
IAM 콘솔에서 AWSDatasyncS3BucketAccess-scd26-handson-rag-docs-toby-5f612 역할을 봅니다.

어떻게 구축 & 설정했는지?

Datasync Task 구성 - Data 전송 옵션 설정 & 구성 검토

- 설정 구성 페이지에서 태스크 모드 설정 및 Task 이름 설정. 설정을 확인하고 Create task 클릭

전송 옵션

전송 모드
DataSync가 소스와 대상 간에 서로 다른 데이터 및 메타데이터만 전송할지 결정합니다.

모든 데이터 전송 ▼

확인
DataSync가 데이터 무결성을 검사하는 방법과 시기를 지정합니다. DataSync는 전송 중에는 항상 데이터 무결성 검사를 수행합니다.

전송된 데이터만 확인 ▼

대역폭 한도
이 태스크가 활용할 최대 네트워크 대역폭을 할당합니다.

☒ 사용 가능한 항목 사용

파일 및 객체 처리

☒ 삭제된 파일 유지
소스에 없는 데이터를 대상에 유지하거나 대상에서 삭제합니다. 전송 모드(를) 모든 데이터 전송(으)로 설정하는 경우, 이 옵션을 선택 취소할 수 없습니다. [자세히 알아보기](#)

☒ 파일 덮어쓰기
소스 데이터(메타데이터 포함)가 변경될 때 대상 데이터를 수정하거나 보존합니다. 전송 모드(를) 모든 데이터 전송(으)로 설정하는 경우, 이 옵션을 선택할 수 없습니다. [자세히 알아보기](#)

객체 태그

☐ 객체 태그 보존
소스 객체 태그를 대상에 복사

▶ 추가 설정

aws

검색

[음선+5]

아시아 태평양 (서울)

bigbread (982534367401)

scd-26

DataSync > 태스크 > 태스크 생성

1단계
소스 위치 구성

2단계
대상 위치 구성

3단계
설정 구성

4단계
검토

검토

1단계: 소스 위치

소스 위치 구성

리전
Asia Pacific (Seoul)
ap-northeast-2

버킷 이름
scd26-crosscloud-handson

서버
storage.googleapis.com

유형
객체 스토리지

서버 프로토콜
HTTPS

액세스 키
..... [표시](#)

경로
/sample-docs/

서버 포트
443

서버 인증서 확인
Amazon Linux 2 CA 신뢰 프로필

태그 (0)

키

값

태그 없음
리소스에 연결된 태그가 없습니다.

2단계: 대상 위치

대상 위치 구성

리전
Asia Pacific (Seoul) ap-northeast-2

S3 버킷
scd26-handson-rag-docs-toby [L](#)

어떻게 구축 & 설정했는지?

Datasync Task 구성 - Data 전송 옵션 설정 & 구성 검토

- 태스크가 생성되면 Start → Start with defaults 클릭하여 데이터 전송을 시작,
- 기록 부분에 DataSync Task가 성공적으로 수행되면? 기록 (상태)에 성공이라고 보임.

The screenshot shows the AWS DataSync console for a task named 'gcs-to-s3-faiss-index'. The task is in a '사용 가능' (Available) state. The 'Start' button is highlighted with a red box, and the 'Start with defaults' button is also highlighted. The task details include:

- 태스크 상태:** 사용 가능
- 최신 실행:** -
- 태스크 모드:** 항상됨
- 생성 시간:** 2026년 6월 21일 오후 11시 47분 35초 GMT+9
- 태스크 ARN:** arn:aws:datasync:ap-northeast-2:982534367401:task/task-06627ffe1cf617bd9

The '소스 위치' (Source Location) section shows:

- 위치 ID:** loc-094cb513bfa007848
- 리전:** Asia Pacific (Seoul)
- 유형:** 객체 스토리지
- 경로:** /sample-docs/
- 버킷 이름:** scd26-crosscloud-handson
- 서버 프로토콜:** HTTPS
- 서버 포트:** 443
- 서버 인증서 확인:** Amazon Linux 2 CA 신뢰 프로필
- 서버:** storage.googleapis.com
- 액세스 키:** 표시
- 시크릿:** aws-datasyncloc-094cb513bfa007848-C4gDOU

The screenshot shows the AWS DataSync console for the same task, 'gcs-to-s3-faiss-index'. The '기록' (Records) tab is selected, and the '상태' (Status) column shows '성공' (Success) for the first record, which is highlighted with a red box. The task details are the same as in the previous screenshot.

The '기록 (1개)' (Records (1)) section shows:

- 기록은 각 태스크 실행을 보여주며, 실행 결과에 대한 정보를 포함합니다.**
- 태스크 실행 찾기:** 검색
- 기록 (1개):**
- 실행 ID:** exec-081f0a7741d88d99e
- 시작 시간:** 2026년 6월 21일 오후 11시 50분 45초 GMT+9
- 기간:** 29 초
- 상태:** 성공

어떻게 구축 & 설정했는지?

Datasync Task - 수행 확인

S3에 데이터를 확인해보면? 데이터가 들어온걸 확인해 볼 수 있습니다.

- 사진에 보이는건 실제 프로젝트에서 활용한 데이터가 아니라.. 용량이 적어 보일 수 있습니다. (실제 데이터는 몇십GB 정도 된 것 같습니다)

Amazon S3 > 버킷 > scd26-handson-rag-docs-toby

scd26-handson-rag-docs-toby 정보

객체 (8)

객체는 Amazon S3에 저장되어 있는 기본 엔터티입니다. [Amazon S3 인벤토리](#)를 사용하여 버킷에 있는 모든 객체의 목록을 얻을 수 있습니다. 다른 사용자가 객체에 액세스할 수 있게 하려면 명시적으로 권한을 부여해야 합니다. [자세히 알아보기](#)

☐	이름	유형	마지막 수정	크기	스토리지 클래스
☐	01-amazon-s3-overview.txt	txt	2026. 6. 21. pm 11:54:21 PM KST	1.5KB	Standard
☐	02-amazon-bedrock-intro.txt	txt	2026. 6. 21. pm 11:54:21 PM KST	1.9KB	Standard
☐	03-rag-technology-guide.txt	txt	2026. 6. 21. pm 11:54:22 PM KST	2.5KB	Standard

MongoDB Compass

GCP Compute Engine 내부에 MongoDB 구축

Compass

My Queries

Data Modeling

CONNECTIONS (2)

rag-mongodb-vm-gcp

Documents 92

Aggregations Schema Indexes 4 Validation

Type a query: { field: 'value' } or [Generate query](#) [Explain](#) [Reset](#) [Find](#) [Options](#)

100 1 - 92 of 92

```
{ "_id": "ObjectId('69f739fe6e231cb3c703ac1f')", "question": "사천시 청년면접수당 지원사업의 신청하기 위한 자격 조건은 무엇인가요?", "ground_truth": "사천시 청년면접수당 지원사업을 신청하려면 만 18세부터 39세 이하의 청년으로, 신청일 기준으로 사천시에 주민등록상 주소지를 둔...", "difficulty": "medium", "qa_type": "factual", "reference_doc": "data_portal/latest.json", "reference_source": "data_portal", "category": "employment", "policy_title": "사천시 청년면접수당 지원사업", "policy_id": "20256122805408210345", "id": "q001", "dataset_id": "youth_policy:1.0:2026-05-03T12:05:13.873077+00:00", "synced_at": "2026-05-03T12:05:13.873077+00:00" }
```

```
{ "_id": "ObjectId('69f739fe6e231cb3c703ac20')", "question": "저는 1995년생으로 현재 사천시에 거주하고 있으며, 2025년 3월에 사천시 소재 기업에 면접을 보았고 면접일 기준 고용보험...", "ground_truth": "네, 귀하의 경우 사천시 청년면접수당 지원사업의 신청권 요건(나이, 거주지, 면접일, 고용보험 미취득)과 사업장 요건(사천시 ...)을 충족합니다.", "difficulty": "hard", "qa_type": "reasoning", "reference_doc": "data_portal/latest.json", "reference_source": "data_portal", "category": "employment", "policy_title": "사천시 청년면접수당 지원사업", "policy_id": "20256122805408210345", "id": "q002", "dataset_id": "youth_policy:1.0:2026-05-03T12:05:13.873077+00:00", "synced_at": "2026-05-03T12:05:13.873077+00:00" }
```

```
{ "_id": "ObjectId('69f739fe6e231cb3c703ac26')", "question": "청년내일저축계좌는 어디에서 어떻게 신청할 수 있나요?" }
```

이렇게 Datasync Task를 설정했고, 한번 Task를 돌려보았는데 느낀점은?



트러블슈팅

1. GCS Endpoint 포맷 설정

- a. GCS 엔드포인트는 반드시 글로벌 주소 storage.googleapis.com에 버킷은 이름만, 서브 디렉토리는 앞뒤 슬래시 붙인 `/index/` 이렇게 사용해 줘야함.
- b. 이렇게 안주면? 틀려도 인증 실패나 '위치가 비었다' 에러가 납니다...

2. IAM 정책 관련

- a. S3의 Destination 부분은 Datasync가 검증하기 때문에, 정책 & 권한이 Task를 수행하기 전에 이전에 이미 생성이 되어 있어야 했음.
- b. 생성이 되어 있지 않으면 오류나서 Task가 실행을 할 수 없음.

느낀점?

- 효율적인 데이터 연동 (AWS DataSync 도입)
 - GCP에 구축된 기존 ETL 파이프라인을 AWS로 전면 이전하는 대신, AWS DataSync를 활용해 필요한 Index 데이터만 가져오는 멀티 클라우드 전략을 채택
- 시간 및 비용 리소스 최적화
 - 전체 인프라를 마이그레이션(GCP → AWS)하고 시스템을 재구축 및 재검증하는 데 소요될 시간과 비용을 절약.
 - 특히, 기존 GCP 인프라는 무료 크레딧을 활용해 구축해 두었기 때문에 비용 효율성을 극대화할 수 있었습니다.
- 운영 트레이드오프 (Trade-off)
 - 두 개의 클라우드 환경(GCP, AWS)을 동시에 모니터링하고 관리해야 하는 운영상의 번거로움(Overhead)은 존재.
- 종합 평가
 - 관리 포인트가 늘어나는 단점이 있었으나, 이미 안정적으로 동작하는 파이프라인을 그대로 유지함으로써 얻는 이점(시간·비용 절감 및 안정성)이 훨씬 컸다고 생각.
 - 결과적으로 현재 상황에 맞는 가장 합리적인 솔루션을 선택했다고 생각

Thanks.



Daehyun Kim



Daehyun-Bigbread



developer_.toby

Presenter: Daehyun Kim
Solutions Architect, MegazoneSoft
前 kakaostyle